



SLAM 学习笔记

- 单目相机

只使用一个摄像头进行SLAM的做法称为单目SLAM

缺点是无法判断尺度(SLAM)—估计值与真实值之间的因子，称为尺度不确定性

- 双目相机

通过左右相机的基线-两个相机之间的距离，结合左右相机获得的图像计算真实像素点的深度（要计算所有像素点），所以双目SLAM的主要问题就是算力

- 深度相机

通过发射和接收光线测定像素点的距离（深度），这种方法使用物理手段比较节省算力

视觉SLAM框架

经典视觉SLAM框架：




图 2-7 经典的视觉 SLAM 框架

视觉里程计

和里程计很像，在较短的时间内通过前几帧的图像信息估计相机运动并进行建图，缺点同理，会因为误差累积造成漂移，为了解决漂移，就需要后端优化和回环检测了

后端优化

后端优化就是如何从带有噪声的数据中估计整个系统的状态，以及这个状态估计的不确定性有多

大——这称为最大后验概率估计（MAP），这里的状态既包括机器人也包括地图
所以SLAM问题的本质就是：对运动主体本身和周围环境空间不确定性的估计

回环检测

用于解决时间漂移问题，通过判断图像之间的相似性，让机器人知道到达了（回到了）某个点，
再对位置估计值进行修正，即可消除漂移

SLAM问题的数学化

我们定义：每一个运动的时刻为 $t = 1, \dots, K$ ，每一个时刻的位置为 $\mathbf{x} = x_1, \dots, x_K$ ，在运动过程中，每一个时刻机器人都会识别到若干个路标，不妨设总共有 N 个路标，分别是 $\mathbf{y} = y_1, \dots, y_N$

接下来我们来定义运动和观测

运动

也就是从 $k - 1$ 时刻到 k 时刻位置 $\mathbf{x}$ 的变化，于是我们可以设定一个运动方程

$$\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k, \mathbf{w}_k)$$

其中 $\mathbf{u}_k$ 就是 k 时刻运动传感器的输入，而 $\mathbf{w}_k$ 就是 k 时刻的噪声， f 用于描述整个过程

观测

描述机器人在 k 时刻 $\mathbf{x}_k$ 位置探测到了某一个路标 y_j
和运动一样，我们可以写一个观测方程

$$\mathbf{z}_{k,j} = h(\mathbf{y}_j, \mathbf{x}_k, \mathbf{v}_{k,j})$$

其中 $\mathbf{z}_{k,j}$ 是一个 k 时刻的观测数据， $\mathbf{v}_{k,j}$ 是观测噪声

综合

综合运动方程和观测方程

$$\begin{cases} \mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k, \mathbf{w}_k), k = 1, \dots, K \\ \mathbf{z}_{k,j} = h(\mathbf{y}_j, \mathbf{x}_k, \mathbf{v}_{k,j}), (k, j) \in \mathcal{O} \end{cases}$$

这就是SLAM过程的两个基本方程，其中 $\mathcal{O}$ 是一个集合，记录了哪个时刻观测到了哪个路标
按照运动观测噪声的线性和非线性、噪声的高斯和非高斯分布来分类，可以将其分为线性/非线性和高斯/非高斯系统

三维空间刚体运动

平移和旋转

对于世界坐标系与相机坐标系，假设它们分别由两组正交基组成 $[\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3]$ 和 $[\mathbf{e}'_1, \mathbf{e}'_2, \mathbf{e}'_3]$
对于一个在三维空间中的向量 $\mathbf{p}$ ，它在不同坐标系下的坐标不同，它不会随着坐标系变换而变换，这两个坐标系之间相差了一个欧式变换

旋转

$\mathbf{p}$ 在 $[\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3]$ 下的坐标表示为 $\begin{bmatrix} p_1 \\ p_2 \\ p_3 \end{bmatrix}$ ，在 $[\mathbf{e}'_1, \mathbf{e}'_2, \mathbf{e}'_3]$ 下的坐标表示为 $\begin{bmatrix} p'_1 \\ p'_2 \\ p'_3 \end{bmatrix}$ ，由于 $\mathbf{p}$ 本身并不会变，所以满足

$$[\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3] \begin{bmatrix} p_1 \\ p_2 \\ p_3 \end{bmatrix} = [\mathbf{e}'_1, \mathbf{e}'_2, \mathbf{e}'_3] \begin{bmatrix} p'_1 \\ p'_2 \\ p'_3 \end{bmatrix}$$

只要我们两边左乘 $\begin{bmatrix} \mathbf{e}_1^T \\ \mathbf{e}_2^T \\ \mathbf{e}_3^T \end{bmatrix}$ 左边的系数就变成了单位矩阵

$$\begin{bmatrix} p_1 \\ p_2 \\ p_3 \end{bmatrix} = \begin{bmatrix} \mathbf{e}_1^T \mathbf{e}'_1 & \mathbf{e}_1^T \mathbf{e}'_2 & \mathbf{e}_1^T \mathbf{e}'_3 \\ \mathbf{e}_2^T \mathbf{e}'_1 & \mathbf{e}_2^T \mathbf{e}'_2 & \mathbf{e}_2^T \mathbf{e}'_3 \\ \mathbf{e}_3^T \mathbf{e}'_1 & \mathbf{e}_3^T \mathbf{e}'_2 & \mathbf{e}_3^T \mathbf{e}'_3 \end{bmatrix} \begin{bmatrix} p'_1 \\ p'_2 \\ p'_3 \end{bmatrix}$$

我们设中间那个大的矩阵为 $\mathbf{R}$ ，这个矩阵由两组基之间的内积组成，所以其仅依赖于两对正交

基的选取，故也称为**旋转矩阵**，也叫它**方向余弦矩阵**，实际上旋转矩阵是一个行列式为1的正交矩阵，反之行列式为1的正交矩阵也是一个旋转矩阵，所以对于 **n** 维旋转矩阵的集合可以如此定义：

$$\text{SO}(n) = \mathbf{R} \in \mathbb{R}^{n \times n} | \mathbf{R}\mathbf{R}^T = \mathbf{I}, \det(\mathbf{R}) = 1$$

其中 **$\text{SO}(n)$** 是特殊正交群，由于 **$\mathbf{R}$** 是一个正交矩阵，所以它的逆（也是转置）则描述了一个相反的旋转：

$$\mathbf{a}' = \mathbf{R}^{-1}\mathbf{a} = \mathbf{R}^T\mathbf{a}$$

平移

除旋转外，对于平移我们只需要一个额外的平移向量即可，按上面的式子我们可以设出坐标系**1**和坐标系**2**，可以得出：

$$\mathbf{a}_1 = \mathbf{R}_{12}\mathbf{a}_2 + \mathbf{t}_{12}$$

，其中 **$\mathbf{t}$** 就是平移向量（坐标系原点指向另一个坐标系原点的向量），旋转矩阵的下标表示把从坐标系**2**的向量变换到坐标系**1**中，注意这里的下标是从右往左读，而平移向量是从左往右读的

变换矩阵与齐次坐标

上述变换的描述正确但不是线性变换，这样做的后果是多次变换后式子会变得麻烦不堪

我们设变换矩阵 **$\mathbf{T} = \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix}$** 并重写 **$\mathbf{a}$** 为 **$\begin{bmatrix} \mathbf{a} \\ 1 \end{bmatrix}$** ， **$\mathbf{a}'$** 同理，称它们为**齐次坐标**。这样我们就能重写之前的变换公式：

$$\begin{bmatrix} \mathbf{a}' \\ 1 \end{bmatrix} = \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \begin{bmatrix} \mathbf{a} \\ 1 \end{bmatrix} = \mathbf{T} \begin{bmatrix} \mathbf{a} \\ 1 \end{bmatrix}$$

这样这个变换就是一个线性变换了，对于多次变换也只需要多次左乘矩阵即可，我们约定如果直接写 **$\mathbf{b} = \mathbf{T}\mathbf{a}$** 那么默认它们已经进行了齐次坐标化（如果是 **$\mathbf{b} = \mathbf{R}\mathbf{a}$** 则不使用齐次坐标）

对于 **$\mathbf{T}$** ，这种矩阵属于**特殊欧氏群** **$\text{SE}(n)$** ，在这里有：

$$\text{SE}(3) = \left\{ \mathbf{T} = \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \in \mathbb{R}^{4 \times 4} | \mathbf{R} \in \text{SO}(3), \mathbf{t} \in \mathbb{R}^3 \right\}$$

与 $\text{SO}(3)$ 一样，该矩阵的逆表示一个反向变换：

$$\mathbf{T}^{-1} = \begin{bmatrix} \mathbf{R}^T & -\mathbf{R}^T \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix}$$

它的下标和旋转矩阵的下标表示方法一致

在这里先给一个符号定义，记 $\mathbf{a}^\wedge = \begin{bmatrix} 0 & -a_3 & a_2 \\ a_3 & 0 & -a_1 \\ -a_2 & a_1 & 0 \end{bmatrix}$ 为向量 $\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix}$ 的反对称矩阵，

用 $^\vee$ 符号则可表示反对称矩阵对应的向量

我们注意到，虽然 $\mathbf{R}$ 能通过两组基来描述两个基坐标系之间的旋转变换，但是我们可以设一个三维向量 $\mathbf{n}$ 用 $\theta\mathbf{n}$ 描述旋转轴为 $\mathbf{n}$ 旋转角度为 θ 的旋转变换（默认按右手定则），我们可以从罗德里格斯公式(Rodrigues's Formula)：

$$\mathbf{R} = \cos \theta \mathbf{I} + (1 - \cos \theta) \mathbf{n} \mathbf{n}^T + \sin \theta \mathbf{n}^\wedge$$

得到旋转矩阵和旋转向量之间的转换公式，同时如果我们两边同时求迹，能得到角度的求解公式：

$$\theta = \arccos \frac{\text{tr}(\mathbf{R}) - 1}{2}$$

四元数

由于不存在不带奇异性的三维向量描述旋转的方式，我们可以使用四元数这种一个实部三个虚部的类复数来表示旋转：

$$\mathbf{q} = q_0 + q_1 i + q_2 j + q_3 k$$

其中三个虚部满足以下表达式：

$$\begin{cases} i^2 = j^2 = k^2 = -1 \\ ij = k, ji = -k \\ jk = i, kj = -i \\ ki = j, ik = -j \end{cases}$$

我们可以用一个标量一个向量表示四元数：

$$\mathbf{q} = [s, \mathbf{v}]^T, s = q_0 \in \mathbb{R}, \mathbf{v} = [q_1, q_2, q_3]^T \in \mathbb{R}^3$$

s 称为四元数的实部， $\mathbf{v}$ 称为四元数的虚部，大部分性质和普通复数一样，四元数的逆被定义为：

$$\mathbf{q}^{-1} = \frac{\mathbf{q}^*}{\|\mathbf{q}\|^2}$$

其中 $\mathbf{q}^*$ 为 $\mathbf{q}$ 的共轭

对于三维点 p 用四元数表示它（将坐标分别设为四元数的三个虚部系数），用四元数 $\mathbf{q}$ 描述从 p 变换到 p' 的旋转变换，满足以下式子：

$$p' = \mathbf{q} p \mathbf{q}^{-1}$$

在这里需要构造的四元数为 $\mathbf{q} = \cos \frac{\theta}{2} + \mathbf{v} \sin \frac{\theta}{2}$

如果不构造这种形式的旋转公式，只乘一次四元数就会导致实部非0，这样操作可以让实部为0

并且旋转角度叠加为 θ ，这是由于 $\mathbf{q}^{-1} = \cos \frac{\theta}{2} - \mathbf{v} \sin \frac{\theta}{2} = \cos(-\frac{\theta}{2}) + \mathbf{v} \sin(-\frac{\theta}{2})$

而左乘正转右乘逆转，所以这里确实是 $\frac{\theta}{2} - (-\frac{\theta}{2}) = \theta$

同时四元数也能写成矩阵，我们定义符号 $^+$ 和 $^\oplus$ ：

$$\mathbf{q}^+ = \begin{bmatrix} s & -\mathbf{v}^T \\ \mathbf{v} & s\mathbf{I} + \mathbf{v}^\wedge \end{bmatrix}, \mathbf{q} = \begin{bmatrix} s & -\mathbf{v}^T \\ \mathbf{v} & s\mathbf{I} - \mathbf{v}^\wedge \end{bmatrix}$$

所以四元数的乘法也可以由上述形式写成矩阵的乘法：

$$\mathbf{q}_1^+ \mathbf{q}_2 = \begin{bmatrix} s_1 & -\mathbf{v}_1^T \\ \mathbf{v}_1 & s_1\mathbf{I} + \mathbf{v}_1^\wedge \end{bmatrix} \begin{bmatrix} s_2 \\ \mathbf{v}_2 \end{bmatrix} = \begin{bmatrix} -\mathbf{v}_1^T \mathbf{v}_2 + s_1 s_2 \\ s_1 \mathbf{v}_2 + s_2 \mathbf{v}_1 + \mathbf{v}_1^\wedge \mathbf{v}_2 \end{bmatrix} = \mathbf{q}_1 \mathbf{q}_2$$

同理能得 $\mathbf{q}_1 \mathbf{q}_2 = \mathbf{q}_2^\oplus \mathbf{q}_1$

我们回到四元数的旋转变换公式：

$$\begin{aligned}\mathbf{p}' &= \mathbf{q}\mathbf{p}\mathbf{q}^{-1} = \mathbf{q}^+ \mathbf{p}^+ \mathbf{q}^{-1} = \mathbf{q}^+ (\mathbf{q}^{-1})^\oplus \mathbf{p} \\ &= \begin{bmatrix} 1 & \mathbf{0} \\ \mathbf{0}^T & \mathbf{v}\mathbf{v}^T + s^2\mathbf{I} + 2s\mathbf{v}^\wedge + (\mathbf{v}^\wedge)^2 \end{bmatrix} \mathbf{p}\end{aligned}$$

注意最后一个矩阵的右下角正是旋转矩阵 $\mathbf{R} = \mathbf{v}\mathbf{v}^T + s^2\mathbf{I} + 2s\mathbf{v}^\wedge + (\mathbf{v}^\wedge)^2$
我们两边同时求迹：

$$\text{tr}(\mathbf{R}) = 4s^2 - 1$$

同时：

$$\theta = \arccos \frac{\text{tf}(\mathbf{R} - 1)}{2} = \arccos(2s^2 - 1) = 2 \arccos s$$

于是我们得到四元数 $\mathbf{q} = \begin{bmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \end{bmatrix}$ 的旋转公式：

$$\begin{cases} \theta = 2 \arccos q_0 \\ \begin{bmatrix} n_x \\ n_y \\ n_z \end{bmatrix} = \frac{1}{\sin \frac{\theta}{2}} \begin{bmatrix} q_1 \\ q_2 \\ q_3 \end{bmatrix} \end{cases}$$

其中 $[n_x, n_y, n_z]^T$ 是单位旋转轴

几何变换

表 3-1 常见变换的性质比较

变换名称	矩阵形式	自由度	不变性质
欧氏变换	$\begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix}$	6	长度、夹角、体积
相似变换	$\begin{bmatrix} s\mathbf{R} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix}$	7	体积比
仿射变换	$\begin{bmatrix} \mathbf{A} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix}$	12	平行性、体积比
射影变换	$\begin{bmatrix} \mathbf{A} & \mathbf{t} \\ \mathbf{a}^T & v \end{bmatrix}$	15	接触平面的相交和相切

李群与李代数

正式定义

群

前文讲述了三维旋转矩阵构成了特殊正交群 $\text{SO}(3)$ ，变换矩阵构成了特殊欧氏群 $\text{SE}(3)$

可以注意到，这两个群都不满足加法封闭性，但是满足乘法封闭性，我们称这种只有一个良好运算的集合为群，它是一种集合加上一种运算的代数结构，我们把集合记作 A ，运算记为 $\cdot$ ，则群可以记作 $G = (A, \cdot)$ ，它拥有四个性质

- 封闭性： $\forall a_1, a_2 \in A, a_1 \cdot a_2 \in A$
- 结合律： $\forall a_1, a_2, a_3 \in A, (a_1 \cdot a_2) \cdot a_3 = a_1 \cdot (a_2 \cdot a_3)$
- 么元： $\exists a_0 \in A, \forall a \in A, a_0 \cdot a = a \cdot a_0 = a$
- 逆： $\forall a \in A, \exists a^{-1} \in A, a \cdot a^{-1} = a_0$

李群是指具有连续（光滑）性质的群， $\text{SO}(n)$ 和 $\text{SE}(n)$ 在实数空间上连续，它们都是李群，我们先从李代数入手再引出李群

李代数

引入

考虑旋转矩阵 $\mathbf{R}$ ，假设它是总随时间变化的一个函数 $\mathbf{R}(t)$ ，那么根据旋转矩阵性质应有

$$\mathbf{R}(t)\mathbf{R}(t)^T = \mathbf{I}$$

两边分别对时间求导可得

$$\dot{\mathbf{R}}(t)\mathbf{R}(t)^T + \mathbf{R}(t)\dot{\mathbf{R}}(t)^T = 0$$

这表示 $\dot{\mathbf{R}}(t)\mathbf{R}(t)^T$ 是一个反对称矩阵，所以我们可以找到一个向量 $\phi(t) \in \mathbb{R}^3$ 与之对应：

$$\dot{\mathbf{R}}(t)\mathbf{R}(t)^T = \phi(t)^\wedge$$

左右同乘 $\mathbf{R}(t)$ 有：

$$\dot{\mathbf{R}}(t) = \phi(t)^\wedge \mathbf{R}(t) = \begin{bmatrix} 0 & -\phi_3 & \phi_2 \\ \phi_3 & 0 & -\phi_1 \\ -\phi_2 & \phi_1 & 0 \end{bmatrix} \mathbf{R}(t)$$

也就是说旋转矩阵求一次导相当于左乘一个 $\phi^\wedge(t)$ 矩阵，设 $\mathbf{R}(0) = \mathbf{I}$ ，我们可以在 $t = 0$ 时进行一价泰勒展开：

$$\mathbf{R}(t) \approx \mathbf{R}(t_0) + \dot{\mathbf{R}}(t_0)(t - t_0) = \mathbf{I} + \phi(t_0)^\wedge(t)$$

这里 $\phi(t_0)$ 仍用 t_0 的原因只是为了表明这个旋转不是从0时刻开始而是从 t_0 时刻开始，即描述从 t_k 到 t_{k+1} 时刻的变化，我们称此时 ϕ 在 $\text{SO}(3)$ 原点附近的正切空间上，同时在 t_0 附近我们可以令 $\phi(t_0) = \phi_0$ 为常数，那么就有

$$\dot{\mathbf{R}}(t) = \phi_0^\wedge \mathbf{R}(t)$$

这是一个微分方程，容易解得：

$$\mathbf{R}(t) = e^{\hat{\phi}_0 t}$$

说明在 $\mathbf{0}$ 附近旋转矩阵还可由这个公式计算

$\mathfrak{so}(3)$

每个李群都有对应的李代数，它描述了李群在单位元附近的正切空间的性质，一般李代数定义如下：

李代数由一个集合 $\mathbb{V}$ 、一个数域 $\mathbb{F}$ 和一个二元运算 $[\cdot, \cdot]$ 组成，如果满足以下性质则称 $(\mathbb{V}, \mathbb{F}, [\cdot, \cdot])$ 为一个李代数，称为 $\mathfrak{g}$

- 封闭性： $\forall \mathbf{X}, \mathbf{Y} \in \mathbb{V}, [\mathbf{X}, \mathbf{Y}] \in \mathbb{V}$
- 双线性： $\forall \mathbf{X}, \mathbf{Y}, \mathbf{Z} \in \mathbb{V}, a, b \in \mathbb{F}$ ，有

$$[a\mathbf{X} + b\mathbf{Y}, \mathbf{Z}] = a[\mathbf{X}, \mathbf{Z}] + b[\mathbf{Y}, \mathbf{Z}], [\mathbf{Z}, a\mathbf{X} + b\mathbf{Y}] = a[\mathbf{Z}, \mathbf{X}] + b[\mathbf{Z}, \mathbf{Y}]$$

- 自反性： $\forall \mathbf{X} \in \mathbb{V}, [\mathbf{X}, \mathbf{X}] = 0$
- 雅可比等价： $\forall \mathbf{X}, \mathbf{Y}, \mathbf{Z} \in \mathbb{V}, [\mathbf{X}, [\mathbf{Y}, \mathbf{Z}]] + [\mathbf{Z}, [\mathbf{X}, \mathbf{Y}]] + [\mathbf{Y}, [\mathbf{Z}, \mathbf{X}]] = 0$

其中二元运算也被称作**李括号**，实际上三维向量 $\mathbb{R}^3$ 上的叉积也是一种李代数，因此 $\mathfrak{g} = (\mathbb{R}^3, \mathbb{R}, \times)$ 构成了一个李代数（第四条性质可用**拉格朗日公式**也称**BAC - CAB公式**推导）实际上之前提到的 ϕ 也是一个李代数， $\mathbf{SO}(3)$ 对应的李代数是定义在 $\mathbb{R}^3$ 上的向量，每个 ϕ 都可生成一个反对称矩阵：

$$\Phi = \phi^\wedge = \begin{bmatrix} 0 & -\phi_3 & \phi_2 \\ \phi_3 & 0 & -\phi_1 \\ -\phi_2 & \phi_1 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 3}$$

在此定义下，两个向量的李括号为：

$$[\phi_1, \phi_2] = (\Phi_1 \Phi_2 - \Phi_2 \Phi_1)^\vee$$

易验证知其满足李代数性质，我们称 $\mathfrak{so}(3)$ 的元素是三维向量或三维反对称矩阵（因为一一对应）：

$$\mathfrak{so}(3) = \{\phi \in \mathbb{R}^3, \Phi = \phi^\wedge \in \mathbb{R}^{3 \times 3}\}$$

我们可以利用指数映射用 $\mathfrak{so}(3)$ 表示 $\mathrm{SO}(3)$ 的旋转矩阵

$\mathfrak{se}(3)$

对于 $\mathrm{SE}(3)$ 它也有对应的 $\mathfrak{se}(3)$ ：

$$\mathfrak{se}(3) = \left\{ \xi = \begin{bmatrix} \rho \\ \phi \end{bmatrix} \in \mathbb{R}^6, \rho \in \mathbb{R}^3, \phi \in \mathfrak{so}(3), \xi^\wedge = \begin{bmatrix} \phi^\wedge & \rho \\ \mathbf{0}^T & 0 \end{bmatrix} \in \mathbb{R}^{4 \times 4} \right\}$$

在这里符号 $^\wedge$ 和 $^\vee$ 并不是向量到反对称矩阵和反对称矩阵到向量的关系，仅仅是向量到矩阵矩阵到向量的关系，虽然在这里 ρ 还不是平移向量，但可以先当作平移向量理解， ξ 的李括号是：

$$[\xi_1, \xi_2] = (\xi_1^\wedge \xi_2^\wedge - \xi_2^\wedge \xi_1^\wedge)^\vee$$

指对映射

$\mathfrak{so}(3)$

我们先对矩阵的指数映射下定义：

$$e^{\mathbf{A}} = \sum_{n=0}^{\infty} \frac{1}{n!} \mathbf{A}^n$$

结果仍是矩阵（如果公式收敛），这个公式并不好计算，我们可以使用

$$\begin{cases} \mathbf{a}^\wedge \mathbf{a}^\wedge = \begin{bmatrix} -a_2^2 - a_3^2 & a_1 a_2 & a_1 a_3 \\ a_1 a_2 & -a_1^2 - a_3^2 & a_2 a_3 \\ a_1 a_3 & a_2 a_3 & -a_1^2 - a_2^2 \end{bmatrix} = \mathbf{a} \mathbf{a}^T - \mathbf{I} \\ \mathbf{a}^\wedge \mathbf{a}^\wedge \mathbf{a}^\wedge = \mathbf{a}^\wedge (\mathbf{a} \mathbf{a}^T - \mathbf{I}) = -\mathbf{a}^\wedge \end{cases}$$

将上述公式转化为罗德里格斯公式，也就是说 $\mathfrak{so}(3)$ 实际上是由旋转向量组成的空间，指数映射即所谓的罗德里格斯公式

反之我们也可以定义对数映射从 $\mathrm{SO}(3)$ 到 $\mathfrak{so}(3)$ ：

$$\phi = \ln(\mathbf{R})^\vee = \left[\sum_{n=0}^{\infty} \frac{(-1)^n}{n+1} (\mathbf{R} - \mathbf{I})^{n+1} \right]^\vee$$

直接计算当然不现实，我们设 θ 和 $\mathbf{n}$ 分别是 ϕ 的旋转角度和旋转轴向量使用以下公式：

$$\begin{cases} \theta = \arccos \frac{\text{tr}(\mathbf{R}) - 1}{2} \\ \mathbf{R} = \cos \theta \mathbf{I} + (1 - \cos \theta) \mathbf{n} \mathbf{n}^T + \sin \theta \mathbf{n}^\wedge \end{cases}$$

就能计算出 $\mathbf{R} - \mathbf{R}^T$ 进一步算出 $\phi = \theta \mathbf{n}$ 即

$$\phi = \frac{\theta}{2 \sin \theta} (\mathbf{R} - \mathbf{R}^T)^\vee$$

注意奇异点的计算即可

$\mathfrak{se}(3)$

$\mathfrak{se}(3)$ 上的指对映射也能类似推导，其指数映射形式为：

$$e^{\xi^\wedge} \triangleq \begin{bmatrix} \mathbf{R} & \mathbf{J}\rho \\ \mathbf{0}^T & 1 \end{bmatrix} = \mathbf{T}$$

$$\text{其中 } \sum_{n=0}^{\infty} \frac{(\phi^\wedge)^n}{(n+1)!} = \frac{\sin \theta}{\theta} \mathbf{I} + (1 - \frac{\sin \theta}{\theta}) \mathbf{n} \mathbf{n}^T + \frac{1 - \cos \theta}{\theta} \mathbf{n}^\wedge = \mathbf{J}$$

而对数映射需要 $\xi = \begin{bmatrix} \rho \\ \phi \end{bmatrix}$ ，第二个分量我们在 $\mathfrak{so}(3)$ 的对数映射已经求了，重点是第一个分量，观察 $\mathbf{T}$ 能得到 $\rho = \mathbf{J}^{-1} \mathbf{t}$ ，我们已经通过 θ 得到了 $\mathbf{J}$ ，只需求解 $\mathbf{J}^{-1}$ 即可：

$$\mathbf{J}^{-1} = \frac{\theta}{2} \cot \frac{\theta}{2} \mathbf{I} + (1 - \frac{\theta}{2} \cot \frac{\theta}{2}) \mathbf{n} \mathbf{n}^T - \frac{\theta}{2} \mathbf{n}^\wedge$$

最后我们可以得到如图转换关系





图 4-1 $SO(3), SE(3), \mathfrak{so}(3), \mathfrak{se}(3)$ 的对应关系

求导与扰动模型

在 $SO(3)$ 上的两个矩阵 A, B 相乘是否对应了其 $\mathfrak{so}(3)$ 上的两个矩阵相加即：

$$e^{\phi_1^\wedge} e^{\phi_2^\wedge} = e^{(\phi_1 + \phi_2)^\wedge}$$

当元素为标量这是显然的，但当其为函数却不成立，我们相当于在研究：

$$\ln e^A e^B = A + B$$

这个在矩阵运算中并不成立，但是我们能通过Baker – Campbell – Hausdorff, BCH公式得到：

$$\ln e^A e^B = A + B + \frac{1}{2}[A, B] + \frac{1}{12}[A, [A, B]] - \frac{1}{12}[B, [A, B]] + \dots$$

在 ϕ_1, ϕ_2 分别为小量时该公式可线性表达为 $\mathbf{J}_l(\phi_2)^{-1}\phi_1 + \phi_2$ 和 $\mathbf{J}_r(\phi_1)^{-1}\phi_2 + \phi_1$ ，这里的 $\mathbf{J}(\phi)$ 是一个函数，由于 $\phi = \theta \mathbf{n}$ ，所以这个函数的结果就是之前推导出来的由 θ 和 $\mathbf{n}$ 组成的 $\mathbf{J}$ 计算公式

也不难证明左乘雅可比矩阵相当于右乘自变量为负的雅可比矩阵：（这里的左右乘仍然在主体左边，左右是相对于变换来说的）

$$\mathbf{J}_r(\phi) = \mathbf{J}_l(-\phi)$$

例如，对于 $\mathfrak{so}(3)$ 上一个旋转 ϕ ，给它左乘一个微小旋转 $\Delta \mathbf{R}$ ，对应的李代数为 $\Delta \phi$ ，在李群到李代数上就是：

$$\Delta \mathbf{R} \cdot \mathbf{R} = e^{(\phi + \mathbf{J}_l^{-1}(\phi) \Delta \phi)^\wedge}$$

如果在李代数上加法，那从李代数到李群上就是：

$$e^{(\phi + \Delta \phi)^\wedge} = e^{(\mathbf{J}_l \Delta \phi)^\wedge} \mathbf{R} = \mathbf{R} e^{(\mathbf{J}_r \Delta \phi)^\wedge}$$

在 $\mathfrak{se}(3)$ 上也有类似的结论，不过这里的 $\mathbf{J}$ 要换成 $\mathcal{J}$ ，这是一个 6×6 矩阵，形式较为复杂暂不讨论

$\mathfrak{so}(3)$ 上的求导

背景

假设一个机器人相对于世界坐标系的变换矩阵 $\mathbf{T}$ ，它观察到了一个世界坐标位于 $\mathbf{p}$ 的点，产生了一个观测数据 $\mathbf{z}$ ，那么有：

$$\mathbf{z} = \mathbf{T}\mathbf{p} + \mathbf{w}$$

其中 $\mathbf{w}$ 是随机噪声，我们的目的是计算实际与观测数据的误差 $\mathbf{e} = \mathbf{z} - \mathbf{T}\mathbf{p}$ 并使若观测到了 N 个点，生成的 N 个数据误差最小：

$$\min_{\mathbf{T}} J(\mathbf{T}) = \sum_{i=1}^N \|\mathbf{z}_i - \mathbf{T}\mathbf{p}\|_2^2$$

求解此问题，需要计算目标函数 J 关于变换矩阵 $\mathbf{T}$ 的导数，然而由于李群这种非欧空间没有良定义的加法，导致导数的定义也无从谈起，所以我们不能对位姿求导，只能在李代数上求导：

- 以李代数的姿态向量表示变换矩阵，然后根据李代数的加法对李代数求导
- 对李群左乘或右乘微小扰动，然后对该扰动求导，称为左扰动和右扰动模型

李代数求导

对于空间点 $\mathbf{p}$ 和旋转 $\mathbf{R}$ ，我们无法计算 $\frac{\partial(\mathbf{R}\mathbf{p})}{\partial \mathbf{R}}$ ，因为 $\text{SO}(3)$ 没有加法，所以我们计算李代数形式的导数：

$$\frac{\partial(e^{\phi^\wedge} \mathbf{p})}{\partial \phi}$$

按照导数的定义可算得 $\frac{\partial(e^{\phi^\wedge} \mathbf{p})}{\partial \phi} = -(\mathbf{R}\mathbf{p})^\wedge \mathbf{J}_l$

唯一的问题是这里含有形式较为复杂的 $\mathbf{J}_l$

扰动模型

我们对 $\mathbf{R}$ 进行一次扰动 $\Delta \mathbf{R}$ （李代数下是 φ ），观察结果相对于扰动的变化率，左乘右乘无所谓只会有一点差异，假设左扰动，此时我们要计算的就是 φ 关于函数 $g(\varphi) = e^{\varphi^\wedge} \mathbf{R}\mathbf{p}$ 在 $\varphi = 0$ 处的导数：

$$\frac{\partial \mathbf{R}\mathbf{p}}{\partial \varphi} = \lim_{\varphi \rightarrow 0} \frac{e^{\varphi^\wedge} e^{\phi^\wedge} \mathbf{p} - e^{\phi^\wedge} \mathbf{p}}{\varphi} = -(\mathbf{R}\mathbf{p})^\wedge$$

$\text{SE}(3)$ 上的李代数求导的扰动模型为：

$$\frac{\partial(\mathbf{T}\mathbf{p})}{\partial \Delta \xi} = \begin{bmatrix} \mathbf{I} & -(\mathbf{R}\mathbf{p} + \mathbf{t})^\wedge \\ \mathbf{0}^T & \mathbf{0}^T \end{bmatrix} = (\mathbf{T}\mathbf{p})^\odot$$

这里 $^\odot$ 是被定义的一个算符，它把一个齐次坐标空间点变换成一个 4×6 的矩阵，在这里我们约定符号写法规则：

$$\frac{\mathrm{d}\begin{bmatrix} \boldsymbol{a} \\ \boldsymbol{b} \end{bmatrix}}{\mathrm{d}\begin{bmatrix} \boldsymbol{x} \\ \boldsymbol{y} \end{bmatrix}} = \begin{bmatrix} \frac{\mathrm{d}\boldsymbol{a}}{\mathrm{d}\boldsymbol{x}} & \frac{\mathrm{d}\boldsymbol{a}}{\mathrm{d}\boldsymbol{y}} \\ \frac{\mathrm{d}\boldsymbol{b}}{\mathrm{d}\boldsymbol{x}} & \frac{\mathrm{d}\boldsymbol{b}}{\mathrm{d}\boldsymbol{y}} \end{bmatrix}$$

相似变换

对于一个空间内的点 $\boldsymbol{p}$ ，经过相似变换后的点为 $\boldsymbol{p}'$ ，则：

$$\boldsymbol{p}' = \begin{bmatrix} s\boldsymbol{R} & \boldsymbol{t} \\ \mathbf{0}^T & 1 \end{bmatrix} = s\boldsymbol{R}\boldsymbol{p} + \boldsymbol{t}$$

尺度 s 表示对 $\boldsymbol{p}$ 进行了一次缩放，这个变换矩阵也构成一个相似变换群 $\text{Sim}(3)$ ：

$$\text{Sim}(3) = \left\{ \boldsymbol{S} = \begin{bmatrix} s\boldsymbol{R} & \boldsymbol{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \in \mathbb{R}^{4 \times 4} \right\}$$

其也有对应的李代数 $\mathfrak{sim}(3)$ ，其内的元素 ζ 为七维向量，前六维和 $\mathfrak{se}(3)$ 相同，最后多了一项 σ ：

$$\mathfrak{sim}(3) = \left\{ \zeta | \zeta = \begin{bmatrix} \rho \\ \phi \\ \sigma \end{bmatrix} \in \mathbb{R}^7, \zeta^\wedge = \begin{bmatrix} \sigma \boldsymbol{I} + \phi^\wedge & \rho \\ \mathbf{0}^T & 0 \end{bmatrix} \in \mathbb{R}^{4 \times 4} \right\}$$

也比 $\mathfrak{se}(3)$ 多一项 σ ，关联李群和李代数的指数映射为：

$$e^{\zeta^\wedge} = \begin{bmatrix} e^\sigma e^{\phi^\wedge} & \boldsymbol{J}_s \rho \\ \mathbf{0}^T & 1 \end{bmatrix}$$

$$\text{其中 } \boldsymbol{J}_s = \frac{e^\sigma - 1}{\sigma} \boldsymbol{I} + \frac{\sigma e^\sigma \sin \theta + \theta(1 - e^\sigma \cos \theta)}{\sigma^2 + \theta^2} \boldsymbol{a}^\wedge + \left(\frac{e^\sigma - 1}{\sigma} - \frac{\sigma(e^\sigma \cos \theta - 1) + \theta(e^\sigma \sin \theta)}{\sigma^2 + \theta^2} \right) \boldsymbol{a}^\wedge \boldsymbol{a}^\wedge$$

Sophus库

先介绍几个轨迹误差：

对于估计轨迹 $\mathbf{T}_{\text{esti},i}$ 和真实轨迹 $\mathbf{T}_{\text{gt},i}$ ，其中 $i = 1, \dots, N$

- 绝对轨迹误差(Absolute Trajectory Error, ATE)：

$$\text{ATE}_{\text{all}} = \sqrt{\frac{1}{N} \sum_{i=1}^N \|\log(\mathbf{T}_{\text{gt},i}^{-1} \mathbf{T}_{\text{esti},i})^\vee\|_2^2}$$

其中 $\log$ 表示以2为底

- 绝对平移误差(Average Translational Error)

$$\text{ATE}_{\text{trans}} = \sqrt{\frac{1}{N} \sum_{i=1}^N \|\text{trans}(\mathbf{T}_{\text{gt},i}^{-1} \mathbf{T}_{\text{esti},i})\|_2^2}$$

其中 trans 表示内部向量的平移部分

- 相对位姿误差(Relative Pose Error, RPE)

$$\text{RPE}_{\text{all}} = \sqrt{\frac{1}{N - \Delta t} \sum_{i=1}^{N - \Delta t} \|\log((\mathbf{T}_{\text{gt},i}^{-1} \mathbf{T}_{\text{gt},i+\Delta t})^{-1} (\mathbf{T}_{\text{esti},i}^{-1} \mathbf{T}_{\text{esti},i+\Delta t}))^\vee\|_2^2}$$

- 相对位姿误差平移部分

只需要将RPE的 $\log$ 换成 trans 再去掉 $^\vee$ 即可

非线性优化

状态估计

批量方法主要将从0时刻到 k 时刻的所有输入和观测数据放一起，带回算力中心统一处理，这正是SfM的主流做法，但是这种做法不实时，我们先介绍批量优化方法

记从1到 N 的所有时刻，有 M 个路标点，所有时刻的机器人位姿和路标点坐标为：

$$\mathbf{x} = \mathbf{x}_1, \dots, \mathbf{x}_N, \mathbf{y} = \mathbf{y}_1, \dots, \mathbf{y}_N$$

类似定义 u 是所有时刻的输入， z 是所有时刻的观测数据，于是对机器人状态的估计，就是在已知 u, z 的条件下，求状态 x, y 的条件概率分布（实际上类似于点云分布，点越密集的地方小车越有可能在那里，在这里就是概率越高的地方小车越有可能在那里）：

$$P(x, y|z, u)$$

不知道输入的情况下也是相当于估计 $P(x, y|z)$ ，此问题也是SfM，由贝叶斯公式：

$$P(x, y|z, u) = \frac{P(z, u|x, y)P(x, y)}{P(z, u)} \propto P(z, u|x, y)P(x, y)$$

这里最右边的式子第一因子被称为似然(Likelihood)，第二因子被称为先验，于是最左边的式子就被称为后验了，有：

$$(x, y)_{\text{MAP}}^* = \arg \max P(x, y|z, u) = \arg \max P(z, u|x, y)P(x, y)$$

如果没有了先验（不知道机器人的位姿或路标位置），那么就可以求解最大似然估计：

$$(x, y)_{\text{MLE}}^* = \arg \max P(z, u|x, y)$$

这里的似然可以理解为在某个位姿下，能产生怎样的观测数据

批量状态估计

回到观测方程 $z_{k,j} = h(y_j, x_k) + v_{k,j}$ ，我们假设噪声项 $v_k \sim \mathcal{N}(0, Q_{k,j})$ （即满足正态分布），所以有：

$$P(z_{j,k}|x_k, y_j) = N(h(y_j, x_k), Q_{k,j})$$

考虑正态分布的概率密度函数展开形式取负对数后，可以得到：

$$(x_k, y_j)^* = \arg \min ((z_{k,j} - h(x_k, y_k))^T Q_{k,j}^{-1} (z_{k,j} - h(x_k, y_j)))$$

该式等价于最小化误差的一个二次型，这个二次型称为马哈拉诺比斯距离，也称马氏距离，其中

$\mathbf{Q}_{k,j}^{-1}$ 称为**信息矩阵**，即高斯分布协方差矩阵之逆

我们定义输入和观测数据与模型之间的误差：

$$\begin{aligned} e_{u,k} &= x_k - f(x_{k-1}, u_k) \\ e_{z,j,k} &= z_{j,k} - h(x_k, y_j) \end{aligned}$$

我们各时刻的输入和观测均独立，同时输入与观测也是独立的，有：

$$P(z, u|x, y) = \prod_k P(u_k|x_{k-1}, x_k) \prod_{k,j} P(z_{k,j}|x_k, y_j)$$

之后利用负对数，我们能得到一个最小二乘问题：

$$\min J(x, y) = \sum_k e_{u,k}^T \mathbf{R}_k^{-1} e_{u,k} + \sum_k \sum_j e_{z,k,j}^T \mathbf{Q}_{k,j}^{-1} e_{z,k,j}$$

非线性最小二乘

对于一个简单的最小二乘问题：

$$\min_x F(x) = \frac{1}{2} \|f(x)\|_2^2$$

其中 f 是任意标量非线性函数 $f(x) : \mathbb{R}^n \mapsto \mathbb{R}$

我们只要求解 $\frac{dF}{dx} = 0$ 这个方程即可，之后逐个比较函数值大小就能得到想要的极值，如果 f 是简单的线性函数，那么这个问题就是简单的线性最小二乘问题，然而若其为非线性函数，则需要用迭代的方式，从一个初始值出发使目标函数下降，转化为一个不断寻找下降增量 Δx_k 的问题，具体步骤就是：

- i. 给定某个初始值 x_0
- ii. 对于第 k 次迭代，寻找一个增量 Δx_k ，使得 $\|f(x_k + \Delta x_k)\|_2^2$ 达到极小值
- iii. 若 Δx_k 足够小，则停止（求解后的 Δx_k ，此时意味着结果和上一次相差极小）
- iv. 否则，令 $x_{k+1} = x_k + \Delta x_k$ ，回到步骤2

一阶和二阶梯度法

考虑第 k 次迭代，在 x_k 处进行泰勒展开：

$$F(x_k + \Delta x_k) \approx F(x_k) + \mathbf{J}(x_k)^T \Delta x_k + \frac{1}{2} \Delta x_k^T \mathbf{H}(x_k) \Delta x_k$$

其中 $\mathbf{J}(x_k)$ 是 $F(x)$ 关于 x 的一阶导数，也称梯度、雅可比矩阵， $\mathbf{H}$ 则是二阶导数，也称海塞矩阵，我们再指定一个步长 λ 和方向（梯度方向的反向 $\Delta x^* = -\mathbf{J}(x_k)$ ），就变成了最速下降法，此时增量方程可简写为：

$$\Delta x^* = \arg \min (F(x) + \mathbf{J}(x)^T \Delta x + \frac{1}{2} \Delta x^T \mathbf{H} \Delta x)$$

求右侧等式关于 Δx 的导数并令其为0，得到：

$$\mathbf{J} + \mathbf{H} \Delta x = 0 \Rightarrow \mathbf{H} \Delta x = -\mathbf{J}$$

这样我们得到了增量，该方法又称为牛顿法

高斯-牛顿法

由于牛顿法存在容易走出锯齿路线与增加过多迭代次数的问题，所以高斯-牛顿法反而是另一个不错的选择，它选择一阶泰勒展开 $f(x)$ 而不是 $F(x)$ ，展开后能得到：

$$\Delta x^* = \arg \min_{\Delta x} \frac{1}{2} \|f(x) + \mathbf{J}(x)^T \Delta x\|_2^2$$

再将平方展开上式就得到：

$$\frac{1}{2} (\|f(x)\|_2^2 + 2f(x)\mathbf{J}(x)^T \Delta x + \Delta x^T \mathbf{J}(x)\mathbf{J}(x)^T \Delta x)$$

这实际上是一个QP问题，因为其是一个很明显的二次型最优化问题，所以每次迭代都在求解一个无约束QP问题（所以我们能直接用 `Eigen` 库的 `ldlt().solve()` 来求解），令其为0可以得到：

$$\mathbf{J}(x)\mathbf{J}^T(x)\Delta x = -\mathbf{J}(x)f(x)$$

得到一个**增量方程**，也称高斯牛顿方程、正规方程，记左边的系数为 $\mathbf{H}(x)$ ，右边定义为 $g(x)$ 。整个迭代过程的开始和结束是一样的，只不过中间步骤换为了先求解雅可比矩阵和误差，再求解上述得到的增量方程。

然而这个方法如果遇到了 $\mathbf{J}\mathbf{J}^T$ 为奇异矩阵或者病态矩阵（因为其只有半正定性）时稳定性较差，如果假设其永远正定，那么可能还会导致更夸张的事态。

列文伯格-马夸尔特方法

为了解决 $\mathbf{J}\mathbf{J}^T$ 非正定（不过它至少一定是半正定，可能会在机器人在**退化场景**中出现此问题）导致的解错误问题，列文伯格-马夸尔特方法通过将 $\mathbf{H}$ 改为 $\mathbf{J}\mathbf{J}^T + \lambda\mathbf{I}$ ，只要 $\lambda > 0$ ，那么 $\mathbf{H}$ 就是正定的。先换个角度来说，问题的实际上出在高斯牛顿法算出来的 Δx 没有约束范围，导致出现问题，所以我们可以先给这个解添加一个范围，称为**信赖区域**，区域内的二阶近似有效，否则无效，我们通过定义一个指标 ρ 来刻画近似的好坏程度：

$$\rho = \frac{f(x + \Delta x) - f(x)}{\mathbf{J}(x)^T \Delta x}$$

分子是实际函数下降的值，分母是近似模型下降的值，如果 ρ 接近1，则近似是好的，可以放大近似范围，反之则是坏的，缩小近似范围，经过改良后的算法步骤是：

- i. 给定初始值 x_0 与初始优化半径 μ
- ii. 对于第 k 次迭代，求解

$$\min_{\Delta x_k} \frac{1}{2} \|f(x_k) + \mathbf{J}(x_k)^T \Delta x_k\|^2, \text{ s.t. } \|\mathbf{D} \Delta x_k\|^2 \leq \mu$$

其中 μ 是信赖半径， $\mathbf{D}$ 为系数矩阵

- iii. 计算 ρ
- iv. 若 $\rho > \frac{3}{4}$ ，则设置 $\mu = 2\mu$ ，若 $\rho < \frac{1}{4}$ ，则设置 $\mu = 0.5\mu$
- v. 若 ρ 大于某阈值，则认为近似可行，令 $x_{k+1} = x_k + \Delta x_k$
- vi. 判断算法是否收敛，不收敛返回第二步，否则结束

$\mathbf{D}$ 可以为单位阵也可以为非负数对角矩阵（通常取 $\mathbf{J}^T \mathbf{J}$ 的对焦元素平方根），当其为单位阵时这个 Δx_k 被约束在一个球中，非单位阵则对应椭球，对于这种问题，我们可以使用拉格朗日乘子法：

$$\mathcal{L}(\Delta x_k, \lambda) = \frac{1}{2} \|f(x_k) + \mathbf{J}(x_k)^T \Delta x_k\|^2 + \frac{\lambda}{2} (\|\mathbf{D} \Delta x_k\|^2 - \mu)$$

这里 λ 为拉格朗日乘子，令其关于 Δx 的导数为0，得到增量的线性方程：

$$(\mathbf{H} + \lambda \mathbf{D}^T \mathbf{D}) \Delta x_k = g$$

这里的 $\mathbf{H}$ 和 g 定义与上述的高斯牛顿法一致，当 λ 较小， $\mathbf{H}$ 占主导地位，说明该二次近似模型在该范围内是比较好的，该方法更接近高斯牛顿法。另一方面，当 λ 较大时， $\lambda \mathbf{I}$ 占主导地位，说明该模型的二次近似不够好，该方法更接近于一阶梯度下降法

图优化

概念

我们可以使用因子图（或贝叶斯图）来表示一个最小二乘问题，并使用 `g2o` 库或 `ceres` 库等进行求解。以b-样条曲线平滑路径为例，其需要解决一个线性最小二乘问题

我们可以把原始路径点和待优化路径点都视作图中的顶点，它们都记录了机器人在某时刻的位姿和方向，在图中的位置朝向可以和实际情况一致

随后每个原始路径点与其对应的待优化路径点都有一条边，这些边表示这两个顶点间有关联，同时每一个连续的顶点都需要有边连接，因为他们是相邻关系

随后需要用到因子图中增加的元素，用小正方形表示约束，对于每一个待优化路径点都有一个对应的小正方形与其连接，它所对应的约束是 w_{guide} 即引导权重，引导权重越大，其待优化路径点与对应的原始路径点连接的边的约束就越强，反之则越弱

同时，每4个原始路径点都有一个小正方形一起连接，表示二元约束，刚刚的是一元约束，它对应的约束是 w_{smooth} 即平滑权重，同理的，和引导权重一样，只不过它的变化效果是相反的

解决这个最小二乘问题可以使用 `osqp` 库，它所要解决的问题就是在给定了平滑权重和引导权重的情况下，寻找使得整个图顶点与边位置最恰当的地方的顶点组，即优化所有待优化路径点使得它们既满足平滑权重的约束也满足引导权重的约束

在SLAM建图中也有使用图优化的地方，最重要的是其中用到的回环检测，在记录顶点和边的基础上，回环检测可以通过检测特征相似的顶点并用强约束的边连接，约束越强两个顶点之间拉的越近，它可以有效处理因物理因素而损失的仿真精度，从而使得建的图更精准

而在没有回环检测的情况下，主要考雷达、里程计、imu等方式来进行边约束的设定，使得即使在遇到了退化场景（类似无限长的无明显特征的平直走廊）的情况下，也能较好地完成建图任务

视觉里程计

视觉里程计主要用来根据相邻图像的信息粗略估计出相机的运动，为后端提供初始值，目前主要的算法分为特征点法和直接法

特征点法

特征点

特征点为图像中选取的比较有代表的点，在经典slam中它们被称为路标，而在视觉slam中，它们被称为特征，一般特征的明显程度为：角点>边缘>区块

所以大部分特征识别算法都以识别角点为准，边缘比较不好识别，而区块则更难识别。同时为了解决相机旋转后角点不易识别的情况，还研究出了SIFT、SURF、ORB等算法

特征点主要由关键点和描述子组成，即特征点在图像的大小位姿、描述特征点周围像素的信息的向量，当我们说在一张图像中计算sift特征点时，实际上是指提取sift关键点和计算sift描述子这两件事，一般来说，两个特征点的描述子在向量空间上的距离相近，就可以认为它们是同样的特征点

很多算法都有各自适应的领域，追求精度舍弃时间抑或是相反，都需要仔细衡量，我们可以通过GPU等设备进行加速计算，但是这样会带来slam的成本提升，在使用时需要仔细衡量提升的性能是否匹配得上付出的计算成本

ORB特征

Oriented FAST

orb是在FAST角点上改进以及与改进的BRIEF描述子得来的算法，fast只通过对比亮度的方式确定角点，它的步骤如下：

- i. 在图中选取像素 p ，它的亮度为 I_p
- ii. 设置一个阈值 T （比如 $0.2I_p$ ）
- iii. 以像素 p 为中心，选取半径为3的圆上的16个像素点
- iv. 如果圆上有连续 N 个点的亮度大于 $I_p + T$ 或小于 $I_p - T$ ，那么 p 可被认为是特征点（这个算法根据 N 可以称为FAST - N 算法）

循环以上四步，对每一个像素执行相同的操作，当 $N = 12$ ，还可以通过直接检测第1, 5, 9, 13个像素的亮度，只有同时存在3个像素满足亮度大于 $I_p + T$ 或小于 $I_p - T$ ，才可能是一个角点，否则直接舍弃，同时在一定区域内为了防止出现扎堆现象，还要用非极大值抑制在该区域内

仅保留响应极大值的角点，避免集中

而orb算法在fast算法上增加了旋转和尺度，为了保证尺度不变，orb采用对原始图像进行倍率缩放，不同层堆在一起构成一个金字塔，这样就有了不同分辨率的图像，较小的图像可以看成是远处看过来的场景

在旋转方面，主要计算特征点附近的图像灰度质心，即以图像块灰度值作为权重的中心，它的求解步骤如下：

- i. 在一个图像块 B 中，定义其矩为：

$$m_{pq} = \sum_{x,y \in B} x_p y_q I(x, y), \quad p, q = 0, 1$$

- ii. 通过矩找到图像块的质心：

$$C = \left(\frac{m_{10}}{m_{00}}, \frac{m_{01}}{m_{00}} \right)$$

- iii. 连接图像块的几何中心 O 和质心 C ，得到一个方向向量 $\vec{OC}$ ，于是特征点的方向可以定义为：

$$\theta = \arctan \frac{m_{01}}{m_{10}}$$

在orb中，这种改进后的fast被称为Oriented FAST

BRIEF描述子

BRIEF是由0和1组成的描述向量，它是一个二进制描述子，它表示关键点附近的两个随机像素的大小关系，取了多少个这样的 p, q （两个随机像素），最后得到的就是多少维由0和1组成的向量，改进后的brief算法在提取阶段计算了关键点的方向，所以可以利用方向信息，计算旋转后的Steer BRIEF特征使orb描述子具有较好的旋转不变性

特征匹配

通过对图像与图像或者图像与地图之间的描述子进行准确匹配，称为**特征匹配**，可以为后续的姿态估计、优化等操作减轻大量负担。其存在一瓶颈问题的原因之一就是局部特征存在大量重复纹理，使得特征描述非常相似，此时利用局部特征解决误匹配是非常困难的

在图像 I_t 中提取到特征点 $x_t^m, m = 1, 2, \dots, M$ ，在图像 T_{t+1} 中提取到特征点 $x_{t+1}^n, n = 1, 2, \dots, N$

最简单的匹配方法是暴力匹配，即直接计算所有描述子之间的距离来排序，距离可以用欧式距离，也可以用汉明距离等，我们可以选择更快速的方法快速近似最近邻(FLANN)，基于概率学与哈希的一个算法，它更适合匹配点数量极多的情况

计算相机运动

当有了匹配好的点对，对于不同的相机，估计其运动运用不同的方式：

- i. 单目相机，只知道2D像素坐标，根据两组2D点估计运动，使用对极几何解决
- ii. 双目/RGB-D相机，根据两组3D点估计运动，使用ICP解决
- iii. 一组3D，一组2D点估计运动，即一组3D点和它们在相机的投影位置，使用PnP解决

2D-2D：对极几何

对极约束

对于两帧图像 I_1, I_2 ，它们的相机原点、空间的点 P 对应的特征点分别为 O_1, O_2, p_1, p_2 ，记 O_1O_2 与 I_1, I_2 的交点分别为 e_1, e_2 ， l_1, l_2 分别为 $p_1, e_1; p_2, e_2$ 的连线

我们称点 O_1, O_2, P 确定的平面为极平面，而 e_1, e_2 称为极点， O_1O_2 称为基线， l_1, l_2 称为极线




图 7-9 对极几何约束

只要特征匹配正确，我们就可以求得 P 在空间中的位置，我们设其空间位置为 $P = [X, Y, Z]^T$ ，对于那两个像素点 p_1, p_2 根据针孔相机模型其像素位置为：

$$s_1 p_1 = KP, s_2 p_2 = K(RP + t)$$

这里 K 为相机内参矩阵， R, t 为两个坐标系的相机运动相关矩阵，其中作为齐次坐标的点，如果用一个非零常数乘自身会得到一个投影关系，例如 $s_1 p_1, p_1$ ，它们在齐次坐标的意义下是相等的，这种相等关系被称为尺度意义下相等，记做：

$$sp \simeq p$$

我们设 $x_1 = K^{-1}p_1$ ，同理定义 x_2 经过化简可求得

$$x_2^T t \wedge R x_1 = 0$$

代入 p_1, p_2 有：

$$p_2^T K^{-T} t \wedge R K^{-1} p_1 = 0$$

这两个式子都称为对极约束，其几何意义就是 O_1, O_2, P 三点共面，我们把中间部分记做两个矩阵：基础矩阵 F 和本质矩阵 E ，可得：

$$E = t \wedge R, F = K^{-T} E K^{-1}, x_2^T E x_1 = p_2^T F p_1 = 0$$

所以实际上问题变成了两步，求解 E, F 后求解 R, t

本质矩阵

本质矩阵的定义是 $E = t \wedge R$ ，它是一个 3×3 矩阵，有9个未知数，它有以下三个值得注意的地方：

- E 在不同尺度下是等价的，因为其满足的对极约束是等式为0的约束，乘以任何非零常数约束不变
- 可以证明，其奇异值必定是 $[\sigma, \sigma, 0]^T$ 的形式，这是它的内在性质

- 由于平移和旋转各有3个自由度，所以 $\mathbf{t}^\wedge \mathbf{R}$ 共有6个自由度，但由于尺度等价，实际上本质矩阵只有5个自由度

这表明我们可以用5对点来求解它，不过如果考虑它的尺度等价性，利用8对点来估计 $\mathbf{E}$ ，这就是经典的八点法，其只用了 $\mathbf{E}$ 的线性性质（原式展开后有9个方程，在尺度等价性下剩下8个方程，刚好构成线性方程组），在线性代数框架下求解

考虑一对匹配点，它们的归一化坐标为 $\mathbf{x}_1 = [u_1, v_1, 1]^T$, $\mathbf{x}_2 = [u_2, v_2, 1]^T$ ，把 $\mathbf{E}$ 展开写成向量形式：

$$\mathbf{e} = [e_1, e_2, e_3, e_4, e_5, e_6, e_7, e_8, e_9]^T$$

那么对极约束可以写成：

$$[u_2 u_1, u_2 v_1, u_2, v_2 u_1, v_2 v_1, v_2, u_1, v_1, 1] \cdot \mathbf{e} = 0$$

对于其他7对点，也有类似的方程，于是可以得到一个线性方程组：

$$\begin{bmatrix} u_2^1 u_1^1 & u_2^1 v_1^1 & u_2^1 & v_2^1 u_1^1 & v_2^1 v_1^1 & v_2^1 & u_1^1 & v_1^1 & 1 \\ u_2^2 u_1^2 & u_2^2 v_1^2 & u_2^2 & v_2^2 u_1^2 & v_2^2 v_1^2 & v_2^2 & u_1^2 & v_1^2 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ u_2^8 u_1^8 & u_2^8 v_1^8 & u_2^8 & v_2^8 u_1^8 & v_2^8 v_1^8 & v_2^8 & u_1^8 & v_1^8 & 1 \end{bmatrix} \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ e_5 \\ e_6 \\ e_7 \\ e_8 \\ e_9 \end{bmatrix} = 0$$

$\mathbf{e}$ 位于左侧矩阵的零空间中，如果这个矩阵满秩（= 8），那么零空间维数为 $9 - 8 = 1$ ，也就是 $\mathbf{e}$ 构成一条线，刚好就是其尺度等价性

在解得初步本质矩阵后，如果要恢复相机运动的 $\mathbf{R}, \mathbf{t}$ ，则需要使用奇异值分解(SVD)：

$$\mathbf{E} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$$

注意到 $\mathbf{t}^\wedge$ （反对称矩阵性质及 $\mathbf{t}$ 是单位向量，这里将其进行了归一化长度为1）可以写成：

$$\mathbf{t}^\wedge = \mathbf{U} \mathbf{Z} \mathbf{U}^T$$

$\mathbf{E}$ 和 $\mathbf{t}^\wedge$ 拥有相同的svd左分解矩阵原因是：

$$\mathbf{E}\mathbf{E}^T = \mathbf{t}^\wedge \mathbf{R}(\mathbf{t}^\wedge \mathbf{R})^T = \mathbf{t}^\wedge \mathbf{R}\mathbf{R}^T(\mathbf{t}^\wedge)^T = \mathbf{t}^\wedge(\mathbf{t}^\wedge)^T$$

那么它们的特征向量矩阵即 $\mathbf{U}$ 就是相同的，同时也能得到 $C(\mathbf{E}) = C(\mathbf{t}^\wedge)$

我们定义 $\mathbf{R}_Z(\frac{\pi}{2})$ 表示绕 Z 轴旋转 90° 的旋转矩阵

$$\begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

如果 $\mathbf{E}$ 的奇异值分解正确，那么 $\Sigma = \text{diag}(1, 1, 0)$ ，从而 $\mathbf{Z} = \mathbf{R}_Z(\frac{\pi}{2})\Sigma$ ，于是我们的 $\mathbf{R}$ 必须

为 $\mathbf{U}\mathbf{R}_Z^T(\frac{\pi}{2})\mathbf{V}^T$

由于 $\mathbf{E}$ 正负号等价，所以最后分解的结果一共存在4个可能的解，但只有一个是正确的，我们只

要对 $\mathbf{t}^\wedge, \mathbf{R}$ 进行三角化求它们在相机下的深度，只要两个深度都为正，那就是正确的解
还有一个问题就是，通过线性方程组求解的 $\mathbf{E}$ 的奇异值可能不一定为 $\sigma, \sigma, 0$ 形式（上述推导是在假设奇异值为刚刚所述形式时），我们有两种方法，其中之一就是直接设 $\Sigma = \text{diag}(1, 1, 0)$ ，这是最直接快捷的做法，如果要保证能量稳定，可以其投影到流形上，即：

- $\Sigma = \text{diag}(\sigma_1, \sigma_2, \sigma_3)$ ，假设 $\sigma_1 \geq \sigma_2 \geq \sigma_3$
- 记 $\sigma = \frac{\sigma_1 + \sigma_2}{2}$
- 直接设置新矩阵 $\mathbf{E}' = \mathbf{U}\text{diag}(\sigma, \sigma, 0)\mathbf{V}^T$ 作为接下来分解的本质矩阵

因为 $\mathbf{E}$ 具有尺度等价性，这样做是合理的

单应矩阵

有时候会出现需要解算的空间点 $\mathbf{P}$ 全部位于一个物理平面上（例如在扫描墙体时），此时基于平面投影几何就能解算 $\mathbf{P}$ ，其中需要用到和本质矩阵用途一样的单应矩阵 $\mathbf{H}$

设相机距离 $\mathbf{P}$ 所在平面距离 d ，该平面法向量 $\mathbf{n}$ ，则有：

$$\mathbf{n}^T \mathbf{P} + d = 0$$

整理得 $-\frac{\mathbf{n}^T \mathbf{P}}{d} = 1$

前文讲述了一个尺度相等线性映射：

$$\mathbf{p}_2 \simeq \mathbf{K}(\mathbf{R}\mathbf{P} + \mathbf{t})$$

展开化简得：

$$\mathbf{p}_2 \simeq \mathbf{K}(\mathbf{R} - \frac{\mathbf{t}\mathbf{n}^T}{d})\mathbf{K}^{-1}\mathbf{p}_1$$

如果记右边 $\mathbf{p}_1$ 左乘的一串为矩阵 $\mathbf{H}$ ，其就称为单应矩阵 $\begin{bmatrix} h_1 & h_2 & h_3 \\ h_4 & h_5 & h_6 \\ h_7 & h_8 & h_9 \end{bmatrix}$ ，显然其也有尺度不

变性，注意这里的单应矩阵是在像素坐标系下的单应矩阵，如果要的是归一化坐标系下的单应矩阵，则应把左右的相机内参矩阵 $\mathbf{K}$ 去除

我们用尺度因子展开上式得到：

$$u_2 = \frac{h_1u_1 + h_2v_1 + h_3}{h_7u_1 + h_8v_1 + h_9}$$

$$v_2 = \frac{h_4u_1 + h_5v_1 + h_6}{h_7u_1 + h_8v_1 + h_9}$$

在处理中可以设 $h_9 = 1$ ，整理得：

$$u_2 = h_1u_1 + h_2v_1 + h_3 - h_7u_1u_2 - h_8v_1u_2$$

$$v_2 = h_4u_1 + h_5v_1 + h_6 - h_7u_1u_2 - h_8v_1v_2$$

这样一组匹配点可以构造除了线性相关外两个约束，只需要四对匹配点就能算出自由度为8的单应矩阵（这些特征点不能有三点共线的情况），记 $\mathbf{h} = [h_1, h_2, \dots, h_9]^T$ ，可以列出线性方程组，随后求解这个方程组即可，这称为直接线性变换法(DLt)

和本质矩阵一样，求解出单应矩阵后，对其解算 $\mathbf{R}, \mathbf{t}$ 即可，最后的筛选正确解流程也是一样的

初始化的纯旋转问题

观察上述的求解过程，会发现如果 $\mathbf{t}$ 为0，即相机没有平移而是纯旋转，会导致无法求解 $\mathbf{R}$ ，因为得到的本质矩阵为0，虽然可以用单应矩阵求解，但是无法用三角测量估计特征点的空间位置，所以单目初始化必须要有一定程度的平移

无解（点对过多）情况

如果给的点数多于8对，可以使用最小二乘的思想，设求解本质矩阵时的线性方程组左侧的系数矩阵为 $\mathbf{A}$ ，即方程 $\mathbf{A}\mathbf{e} = \mathbf{0}$ 无解，即无法将 $\mathbf{e}$ 通过 $\mathbf{A}$ 直接变换为 $\mathbf{0}$ ，所以我们改变 $\mathbf{e}$ 使得：

$$\|\mathbf{A}\mathbf{e}\|_2^2$$

最小，即为最小化 $\mathbf{e}^T \mathbf{A}^T \mathbf{A} \mathbf{e}$ 这个二次型，让 $\hat{\mathbf{e}}$ 变化后尽可能接近 $\mathbf{0}$

不过，多出来的点对可能出现误匹配的情况，这样最小二乘法会放大这个误差，此时我们使用另一个方法随机采样一致性(Random Sample Consensus, RANSAC)，和它结合后，整个最小二乘+RANSAC的执行步骤如下：

- i. 随机采样8个点
- ii. 用这8个点通过本质矩阵求解模型参数
- iii. 计算所有点到该模型的距离（对极线距离），距离小于阈值 δ 的记为内点（支持模型的点）
- iv. 如果内点数量超过了之前的记录，则更新最优模型
- v. 回到第一步继续迭代，直到内点数量达到要求或者迭代次数达到上限
- vi. 排除所有非内点，剩下的所有内点进行最小二乘法求出更为精确的 $\mathbf{E}$

三角测量（三角化）

一般来说，我们使用三角测量进行最后的深度测定，来筛选剩下的4个解中错误的解。在此之前，我们先要确定直线 O_1p_1 与 O_2p_2 的交点，理论上，它们是有交点的，但是在存在噪声的情况下，这就有极大的可能不会存在交点，此时我们只需要用最小二乘法即可解得近似解，我们有：

$$s_2 \mathbf{x}_2 = s_1 \mathbf{R} \mathbf{x}_1 + \mathbf{t}$$

其中 s_1, s_2 是两个特征点的深度，我们已知 $\mathbf{R}, \mathbf{t}$ ，要求深度，先介绍除最小二乘法以外的方法。我们同时左乘 $\mathbf{x}_2^\wedge$ ，这样左侧就变为 $\mathbf{0}$ ，通过求解右侧即可求得 s_1 ，这样再带回原式就能求解 s_2 了，这个方法简洁快速，但是存在 $\mathbf{R}, \mathbf{t}$ 影响左侧式子不一定为 $\mathbf{0}$ 的情况，如果使用最小二乘法：

- i. 将左乘前的方程整理成：

$$[\mathbf{R} \mathbf{x}_1 - \mathbf{x}_2] \begin{bmatrix} s_1 \\ s_2 \end{bmatrix} = -\mathbf{t}$$

记为 $A\mathbf{s} = \mathbf{b}$

- iii. 同时左乘 A^T ，求解 $\mathbf{s} = (A^T A)^{-1} A^T (-\mathbf{b})$
- iv. 解得两个点：

$$\begin{cases} \mathbf{P}_1 = \hat{s}_1 \mathbf{x}_1 \\ \mathbf{P}_2 = \mathbf{R}^T (\hat{s}_2 \mathbf{x}_2 - \mathbf{t}) \end{cases}$$

- v. 构造最小化代价函数 $J(s_1, s_2) = \|\mathbf{P}_1 - \mathbf{P}_2\|^2 = \|s_1 \mathbf{x}_1 - (s_2 \mathbf{R}^T \mathbf{x}_2 - \mathbf{R}^T \mathbf{t})\|^2$
- vi. 令 $\mathbf{f}_1 = \mathbf{x}_1, \mathbf{f}_2 = \mathbf{R}^T \mathbf{x}_2$ ，再令 $J(s_1, s_2) = 0$ 并记得到的方程为：

$$A\mathbf{s} = \mathbf{b}$$

$$\text{其中 } A = [\mathbf{f}_1 \quad -\mathbf{f}_2]_{3 \times 2}, \quad \mathbf{s} = \begin{bmatrix} s_1 \\ s_2 \end{bmatrix}_{2 \times 1}, \quad \mathbf{b} = -\mathbf{R}^T \mathbf{t}_{3 \times 1}$$

- vii. 左乘 A^T 求得 $\begin{bmatrix} s_1 \\ s_2 \end{bmatrix}$

- viii. 最后带入回 $\mathbf{P}_1, \mathbf{P}_2$ ，我们最终可以令 $\mathbf{P} = \mathbf{P}_1$ 也可以令其为 $\mathbf{P} = \frac{\mathbf{P}_1 + \mathbf{P}_2}{2}$

值得注意的是，三角测量有它的不确定性，即平移过小，会导致深度的变化值较大，导致不确定性较高，而如果平移过大，则会导致场景改变，即可能会出现新的场景特征。为了解决这个问题，我们其实可以不断观测这个特征点（如果它服从高斯分布），在信息正确的情况下，它的方差会不断减小乃至收敛，这样就得到了一个滤波器，称为深度滤波器DF

PnP

直接线性变换

考虑空间点 P ，它的齐次坐标为 $\mathbf{P} = [X, Y, Z, 1]^T$ ，在图像 I_1 中，投影到特征点 $\mathbf{x}_1 = [u_1, v_1, 1]^T$ ，我们需要求解相机的位姿 $\mathbf{R}, \mathbf{t}$ ，定义增广矩阵 $[\mathbf{R} | \mathbf{t}]$ 为一个 3×4 矩阵 $\mathbf{T}$ ，展开后有：

$$\mathbf{s} \begin{bmatrix} u_1 \\ v_1 \\ 1 \end{bmatrix} = \begin{bmatrix} t_1 & t_2 & t_3 & t_4 \\ t_5 & t_6 & t_7 & t_8 \\ t_9 & t_{10} & t_{11} & t_{12} \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

把尺度因子 $\mathbf{s}$ 消去可以得到两个约束：

$$\begin{cases} u_1 = \frac{t_1X + t_2Y + t_3Z + t_4}{t_9X + t_{10}Y + t_{11}Z + t_{12}} \\ v_1 = \frac{t_5X + t_6Y + t_7Z + t_8}{t_9X + t_{10}Y + t_{11}Z + t_{12}} \end{cases}$$

另定义 $\mathbf{T}$ 的行向量：

$$\mathbf{t}_1 = [t_1, t_2, t_3, t_4]^T, \mathbf{t}_2 = [t_5, t_6, t_7, t_8]^T, \mathbf{t}_3 = [t_9, t_{10}, t_{11}, t_{12}]^T$$

结合上面的式子，可以化简为：

$$\begin{bmatrix} \mathbf{t}_1^T \mathbf{P} - \mathbf{t}_3^T \mathbf{P} u_1 = 0 \\ \mathbf{t}_2^T \mathbf{P} - \mathbf{t}_3^T \mathbf{P} v_1 = 0 \end{bmatrix}$$

我们要求 $\mathbf{t}$ ，每个特征点提供了关于其的两个线性约束，如果有 N 个特征点，可以列出如下线性方程组：

$$\begin{bmatrix} \mathbf{P}_1^T & 0 & -u_1 \mathbf{P}_1^T \\ 0 & \mathbf{P}_1^T & -v_1 \mathbf{P}_1^T \\ \vdots & \vdots & \vdots \\ \mathbf{P}_N^T & 0 & -u_N \mathbf{P}_N^T \\ 0 & \mathbf{P}_N^T & -v_N \mathbf{P}_N^T \end{bmatrix} \begin{bmatrix} \mathbf{t}_1 \\ \mathbf{t}_2 \\ \mathbf{t}_3 \end{bmatrix} = 0$$

求解12维矩阵需要6对匹配点，这种方法称为DLT，当匹配点大于6对，需要使用SVD等方法对超定方程求最小二乘解

然而求得的 $\mathbf{T}$ 的左侧 3×3 部分不一定是 $\text{SO}(3)$ 中的元素，由于噪声的存在，解出来的 $\mathbf{R}$ 不一定满足 $\mathbf{R}\mathbf{R}^T = \mathbf{1}$ （平移向量属于向量空间，好处理），我们可以使用QR分解来完成近似或者使用：

$$\mathbf{R} \leftarrow (\mathbf{R}\mathbf{R}^T)^{-\frac{1}{2}} \mathbf{R}$$

来计算，其为极分解的解析式（这个 $-\frac{1}{2}$ 次幂可以用SVD方式也可以用特征值分解方式计算），极分解表示任意非奇异矩阵 $\mathbf{A}$ 都能分解为 $\mathbf{A} = \mathbf{P}\mathbf{Q}$ 即拉伸矩阵左乘旋转矩阵的形式，其中 $\mathbf{P} =$

$(AA^T)^{-\frac{1}{2}}$ ，所以纯旋转矩阵就能通过不准确的 $\mathbf{R}$ 计算得到 $\mathbf{R}' = (\mathbf{R}\mathbf{R}^T)^{-\frac{1}{2}}\mathbf{R}$ 而qr分解的步骤如下：

- i. 对求出来的不准确矩阵 $\mathbf{A}$ 进行svd分解得到

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$$

- ii. 令 $\mathbf{R} = \mathbf{U}\mathbf{V}^T$ 或者 $\mathbf{R} = \mathbf{U}\text{diag}(1, 1, \det(\mathbf{U}\mathbf{V}^T))\mathbf{V}^T$ ，这里强行把奇异值矩阵变为单位矩阵，这样就满足 $\det(\mathbf{R}) = 1$ 与 $\mathbf{R}\mathbf{R}^T = \mathbf{I}$

它的最小二乘意义是在 Frobenius 范数下，找到的是距离原始矩阵 $\mathbf{A}$ 最近的一个旋转矩阵 $\mathbf{R}$ ，即求解：

$$\min_{\mathbf{R}} \|\mathbf{R} - \mathbf{A}\|_F \quad \text{subject to } \mathbf{R} \in SO(3)$$

P3P

对于P3P，即知道三对3D-2D点对，这样只需要利用三角形相似性质以及几何学定理即可求解相机的位姿

不过它也有缺点，如果点对多于三组，就无法利用多余信息，因为它不在线性代数框架下求解，几何学框架下无法求近似解，同时如果点受到噪声影响，就会存在误匹配，导致算法失效

最小化重投影误差

我们可以把PnP问题构建成一个关于重投影误差的非线性最小二乘问题，把它们全都堪称优化变量，放在一起优化。这类把相机和三维点放一起进行最小化的问题，统称为

Bundle Adjustment

考虑 n 个三维空间点 $\mathbf{P}$ 及投影 $\mathbf{p}$ ，设我们要计算的相机的位姿 $\mathbf{R}, \mathbf{t}$ 的李群表示为 $\mathbf{T}$ ，对于第 i 个空间点坐标 $\mathbf{P}_i = [X_i, Y_i, Z_i]^T$ 的投影像素坐标为 $\mathbf{u}_i = [u_i, v_i]^T$ ，设 $\mathbf{K}$ 为相机内参矩阵，有：

$$s_i \mathbf{u}_i = \mathbf{KTP}_i$$

这个式子有隐含从齐次到非齐次坐标的转换，否则在矩阵乘法上维度不对，我们利用相机位姿未知及观测点的噪声产生的误差进行求和，构建一个最小二乘问题使式子最小化：

$$\mathbf{T}^* = \arg \min_{\mathbf{T}} \frac{1}{2} \sum_{i=1}^n \left\| \mathbf{u}_i - \frac{1}{s_i} \mathbf{KTP}_i \right\|_2^2$$

其中的误差项，是将3D点的投影位置和观测位置作差，称为重投影误差，如图：




图 7-14 重投影误差示意图

随后我们需要使用李代数（转为指数形式）构建无约束优化问题，通过高斯牛顿法等优化算法进行求解，不过在此之前还需要知道每个误差项关于优化变量的导数，即线性化：

$$e(\mathbf{x} + \Delta\mathbf{x}) \approx e(\mathbf{x}) + \mathbf{J}^T \Delta\mathbf{x}$$

对于 $\mathbf{J}^T$ ，我们来求解它，记 $\mathbf{P}' = (\mathbf{TP}_{1:3}) = [X', Y', Z']^T$ 即变换到相机坐标系下的空间点坐标为 $\mathbf{P}'$ 取其前三维，那么有：

$$su = \mathbf{KP}'$$

展开得：

$$\begin{bmatrix} su \\ sv \\ s \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X' \\ Y' \\ Z' \end{bmatrix}$$

消去 s 得到：

$$\begin{cases} u = f_x \frac{X'}{Z'} + c_x \\ v = f_y \frac{Y'}{Z'} + c_y \end{cases}$$

我们对 $\mathbf{T}$ 左乘扰动量 $\delta\boldsymbol{\xi}$ ，考虑 $\mathbf{e}$ 的变化关于扰动量的导数：

$$\frac{\partial \mathbf{e}}{\partial \delta \boldsymbol{\xi}} = \lim_{\delta \boldsymbol{\xi} \rightarrow 0} \frac{\mathbf{e}(\delta \boldsymbol{\xi} \oplus \boldsymbol{\xi}) - \mathbf{e}(\boldsymbol{\xi})}{\delta \boldsymbol{\xi}} = \frac{\partial \mathbf{e}}{\partial \mathbf{P}'} \frac{\partial \mathbf{P}'}{\partial \delta \boldsymbol{\xi}}$$

其中 $\oplus$ 表示李代数上的左乘扰动，第一项为：

$$\frac{\partial \mathbf{e}}{\partial \mathbf{P}'} = - \begin{bmatrix} \frac{\partial u}{\partial X'} & \frac{\partial u}{\partial Y'} & \frac{\partial u}{\partial Z'} \\ \frac{\partial v}{\partial X'} & \frac{\partial v}{\partial Y'} & \frac{\partial v}{\partial Z'} \end{bmatrix} = - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} \end{bmatrix}$$

第二项即为李代数的导数：

$$\frac{\partial(\mathbf{TP})}{\partial \delta \boldsymbol{\xi}} = (\mathbf{TP})^\odot = \begin{bmatrix} \mathbf{I} & -\mathbf{P}'^\wedge \\ \mathbf{0}^T & \mathbf{0}^T \end{bmatrix}$$

$$\text{于是 } \frac{\partial \mathbf{P}'}{\partial \delta \boldsymbol{\xi}} = [\mathbf{I}, -\mathbf{P}'^\wedge]$$

将两项相乘我们能得到 2×6 的雅可比矩阵 $\mathbf{J}^T$

$$\frac{\partial \mathbf{e}}{\partial \delta \boldsymbol{\xi}} = - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} & -\frac{f_x X' Y'}{Z'^2} & f_x + \frac{f_x X'^2}{Z'^2} & -\frac{f_x Y'}{Z'} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} & -f_y - \frac{f_y Y'^2}{Z'^2} & \frac{f_y X' Y'}{Z'^2} & \frac{f_y X'}{Z'} \end{bmatrix}.$$

接下来我们讨论 $\mathbf{e}$ 关于 $\mathbf{P}$ 的导数，用以优化特征点的空间位置（BA是需要的，如果仅运动估计，则只需要位姿就行了，如果仅结构估计，那就只有这个）：

$$\frac{\partial e}{\partial \mathbf{P}} = \frac{\partial e}{\partial \mathbf{P}'} \frac{\partial \mathbf{P}'}{\partial \mathbf{P}}$$

第一项已推导，第二项按照定义有 $\mathbf{P}' = (\mathbf{TP})_{1:3} = \mathbf{RP} + \mathbf{t}$ ，于是：

$$\frac{\partial e}{\partial \mathbf{P}} = - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} // 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} \end{bmatrix} \mathbf{R}$$

使用g2o进行BA优化




图 7-15 PnP 的 BA 的图优化表示

如图为一个PnP的BA的图优化表示，这里的 $\mathbf{T}$ 表示相机位置， $\mathbf{P}_j$ 表示空间点，这两个点为顶点， $\mathbf{z}_j$ 是相机截取到的画面，是不变的观测值， $h(\mathbf{T}, \mathbf{P}_j)$ 是通过这两个顶点计算出来的 $\mathbf{P}_j$ 投影到相机平面上的位置，EdgeProjection是重投影误差，即 $\text{Error} = \mathbf{z}_j - h(\mathbf{T}, \mathbf{P}_j)$ ，用边约束两个顶点表示需要优化这两个点降低重投影误差

3D-3D: ICP

假设我们用RGB-D对两幅图像配对得到了一组配对好了3D点：

$$\mathbf{P} = \{p_1, \dots, p_n\}, \mathbf{P}' = \{p'_1, \dots, p'_n\}$$

我们需要找到一个欧式变换 $\mathbf{R}, \mathbf{t}$ 使得：

$$\forall i, \mathbf{p}_i = \mathbf{R}\mathbf{p}'_i + \mathbf{t}$$

这个问题可以使用迭代最近点(Iterative Closest Point, ICP)求解，这种问题无需考虑相机，同时由于激光数据特征不够丰富，我们无法知道两个点集之间的匹配关系，只能认为距离最近的两个点为同一个，和pnp类似，icp也分线代求解和非线性优化方式求解

SVD方法

定义第 i 对点误差项：

$$\mathbf{e}_i = \mathbf{p}_i - (\mathbf{R}\mathbf{p}'_i + \mathbf{t})$$

构建最小二乘问题，求使误差平方和达到极小的 $\mathbf{R}, \mathbf{t}$ ：

$$\min_{\mathbf{R}, \mathbf{t}} \frac{1}{2} \sum_{i=1}^n \|\mathbf{p}_i - (\mathbf{R}\mathbf{p}'_i + \mathbf{t})\|_2^2$$

定义两组点的质心为它们分量的求和均值 $\mathbf{p}, \mathbf{p}'$ ，我们可以对最小二乘问题的优化目标函数化简得到：

$$\min_{\mathbf{R}, \mathbf{t}} J = \frac{1}{2} \sum_{i=1}^n \|\mathbf{p}_i - \mathbf{p} - \mathbf{R}(\mathbf{p}'_i - \mathbf{p}')\|^2 + \|\mathbf{p} - \mathbf{R}\mathbf{p}' - \mathbf{t}\|^2$$

观察等式，我们只要求得 $\mathbf{R}$ ，第二项令为0就能得到 $\mathbf{t}$ ，所以ICP分为三个步骤求解：

- i. 计算两组点的质心位置 $\mathbf{p}, \mathbf{p}'$ ，然后计算每个点的去质心坐标：

$$\mathbf{q}_i = \mathbf{p}_i - \mathbf{p}, \mathbf{q}'_i = \mathbf{p}'_i - \mathbf{p}'$$

- ii. 计算旋转矩阵：

$$\mathbf{R}^* = \arg \min_{\mathbf{R}} \frac{1}{2} \sum_{i=1}^n \|\mathbf{q}_i - \mathbf{R}\mathbf{q}'_i\|^2$$

- iii. 计算 $\mathbf{t}^* = \mathbf{p} - \mathbf{R}^* \mathbf{p}'$

我们主要求解 $\mathbf{R}$ ，对于目标函数我们展开得到：

$$\frac{1}{2} \sum_{i=1}^n \|\mathbf{q}_i - \mathbf{R} \mathbf{q}'_i\|^2 = \frac{1}{2} \sum_{i=1}^n (\mathbf{q}_i^T \mathbf{q}_i + \mathbf{q}'_i{}^T \mathbf{R}^T \mathbf{R} \mathbf{q}'_i - 2 \mathbf{q}_i^T \mathbf{R} \mathbf{q}'_i)$$

注意到至于第三项与 $\mathbf{R}$ 有关，于是优化目标函数变为：

$$\sum_{i=1}^n -\mathbf{q}_i^T \mathbf{R} \mathbf{q}'_i = -\text{tr}(\mathbf{R} \sum_{i=1}^n \mathbf{q}'_i \mathbf{q}_i^T)$$

用SVD方法能求解这个问题，但是证明很复杂，它的求解步骤如下：

- i. 令 $\mathbf{W} = \sum_{i=1}^n \mathbf{q}_i \mathbf{q}'_i{}^T$
- ii. 对 $\mathbf{W}$ 进行SVD分解得到 $\mathbf{W} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$
- iii. 如果 $\mathbf{W}$ 满秩，则 $\mathbf{R} = \mathbf{U} \mathbf{V}^T$ ，如果 $\det(\mathbf{R}) < 0$ ，则取其相反数

之后解 $\mathbf{t}$ 即可

非线性优化方法

虽然这个最小二乘问题有解细节，没有必要迭代优化，但是实际情况可能会出现深度无法测量的数据点，此时我们可以混合使用PnP和ICP优化，深度已知则建模3D-3D误差，未知则建模3D-2D误差，将所有误差放到同一个问题中考虑，使得求解更加方便。

以李代数表达位姿时，目标函数可以写成：

$$\min_{\xi} = \frac{1}{2} \sum_{i=1}^n \|\mathbf{p}_i - e^{\xi^\wedge} \mathbf{p}'_i\|_2^2$$

我们前面推导了单个误差项关于位姿的导数，直接使用李代数扰动模型：

$$\frac{\partial \mathbf{e}}{\partial \delta \xi} = -(e^{\xi^\wedge} \mathbf{p}'_i)^\odot$$

可以证明，icp问题不会无解，在存在唯一解的情况下，只要找到极小值解，这个极小值就是全局最优值，因此不会遇到局部极小值和非全局最小的情况，也就是它可以任意选定初始值

直接法